

Парсер каталога товаров

Техническое описание v1.0

1. Назначение системы

Парсер каталога товаров предназначен для автоматического сбора данных о товарах с интернет-магазинов. Поддерживает три режима работы: парсинг через публичный API (Wildberries), парсинг через Playwright для JS-рендеринга (Ozon) и универсальный HTML-парсер по CSS-селекторам для любого сайта.

2. Архитектура

2.1 Структура проекта

```
catalog-parser/
├─ main.py — точка входа, CLI-интерфейс
├─ config/ — YAML-конфигурации сайтов
│  └─ wildberries.yaml
│  └─ ozon.yaml
│  └─ generic_example.yaml
├─ src/
│  └─ parser.py — оркестратор, выбор адаптера
│  └─ fetcher.py — HTTP-клиент с retry и rate limit
│  └─ exporters.py — экспорт в CSV и JSON
│  └─ adapters/
│     └─ wildberries.py — API-адаптер WB
│     └─ ozon.py — Playwright-адаптер Ozon
│     └─ html_parser.py — универсальный HTML-парсер
└─ output/ — результаты парсинга
```

2.2 Компоненты системы

Компонент	Технология	Назначение
CatalogParser	Python 3.11+	Оркестратор: выбирает нужный адаптер по конфигу
HttpFetcher	requests + retry	Загрузка страниц с ротацией UA и rate limiting
WildberriesParser	Search API WB	Парсинг через официальный публичный API
OzonParser	Playwright + Chromium	Парсинг JS-рендеренных страниц Ozon
HtmlCatalogParser	BeautifulSoup4 + lxml	Универсальный парсер по CSS-селекторам
exporters	csv, json	Сохранение результатов в CSV и JSON

3. Конфигурация через YAML

Каждый сайт описывается отдельным YAML-файлом в директории config/. Конфиг определяет режим работы, URL, CSS-селекторы, параметры пагинации и rate limiting.

Ключевые параметры конфигурации:

Параметр	Тип	Описание
name	string	Название сайта
mode	api html playwright	Режим парсинга
base_url	string	Базовый URL сайта
selectors.*	CSS-селектор	Селекторы для элементов карточки товара
pagination.type	next_button page_param	Тип пагинации
pagination.max_pages	integer	Максимальное количество страниц
rate_limit.delay_min/max	float (сек)	Задержка между запросами
output.csv_file	string	Имя файла CSV для результатов
output.json_file	string	Имя файла JSON для результатов

4. Собираемые данные

Поле	Тип	Описание
id	integer	Внутренний ID товара на сайте
name	string	Название товара
brand	string	Бренд/производитель
price	float	Актуальная цена (руб.)
original_price	float	Цена без скидки (руб.)
image	string (URL)	Ссылка на главное изображение
url	string (URL)	Ссылка на страницу товара
availability	string	Наличие товара
rating	float	Рейтинг товара (если доступно)
reviews	integer	Количество отзывов (если доступно)

5. Механизм пагинации

Парсер поддерживает три типа пагинации:

Тип	Применение	Принцип работы
page_param	Wildberries API	Передаётся параметр &page=N в URL или запросе
next_button	HTML-сайты	Следует по ссылке в кнопке 'Следующая страница'
scroll_and_button	Ozon (Playwright)	Скроллинг + клик по кнопке пагинации

6. Запуск и использование

Установка зависимостей:

```
pip install -r requirements.txt
playwright install chromium # только для режима playwright
```

Запуск парсинга:

```
# Парсинг Wildberries (API-режим, запрос по умолчанию)
python main.py --config wildberries

# Парсинг WB с кастомным запросом
python main.py --config wildberries --query ноутбук

# Парсинг Ozon (Playwright)
python main.py --config ozon

# Запуск для всех конфигов
python main.py --all

# Кастомный конфиг
python main.py --config /path/to/mysite.yaml --output ./results
```

7. Форматы вывода

CSV (UTF-8 BOM для совместимости с Excel): каждый товар — отдельная строка, заголовки — имена полей. Открывается в Excel, Google Sheets, LibreOffice Calc.

JSON: структура {"total": N, "products": [...]}. Удобен для интеграции с другими системами и дальнейшей обработки.

8. Ограничения и замечания

WB и Ozon активно защищают свои данные от автоматизированного сбора. При частых запросах возможна временная блокировка по IP. Для обхода рекомендуется использовать residential proxy (настраивается через HTTP_PROXY в .env). Ozon требует Playwright + установленного Chromium.

9. Технический стек

Технология	Версия	Назначение
Python	3.11+	Основной язык
requests	2.31	HTTP-клиент для API и HTML
BeautifulSoup4	4.12	Парсинг HTML
lxml	5.1	Быстрый HTML/XML-парсер
Playwright	1.42	Парсинг JS-рендеренных страниц
PyYAML	6.0	Чтение YAML-конфигов
pandas	2.2	Опциональная обработка данных
reportlab	4.1	Генерация PDF-документов