

Портфолио — парсинг, очереди, Telegram-боты

Python-разработка: парсинг сайтов с обходом CloudFlare, очереди RabbitMQ, Telegram-боты на aiogram. Три законченных production-ready прототипа с документацией.


01 · News Parser — парсер новостных сайтов с RabbitMQ

Producer / Consumer · CloudFlare bypass · YAML-конфиг сайтов

Модульная система сбора статей с lenta.ru, rbc.ru, tass.ru. Scraper обходит CloudFlare через cloudscraper, parser применяет XPath-селекторы из YAML, консьюмер читает задачи из RabbitMQ и публикует результаты в отдельные очереди. Новый сайт — новая секция в YAML без правок кода.

- 3 независимые durable-очереди: news_urls → news_articles + news_errors, TTL 24 часа
- Retry x3 с экспоненциальным backoff (HTTP 403/429/503), NACK-в-DLQ, автопереподключение к брокеру
- Rate limiting 6–12 сек между запросами, ротация User-Agent, поддержка Docker-развёртывания RabbitMQ
- Валидация: статья принимается только если есть заголовок и текст ≥ 100 символов

Стек: Python 3.10+ · cloudscraper · lxml · pika · PyYAML · RabbitMQ 3.13 · Docker



RabbitMQ Management							
Cluster: rabbit@vps							
Overview Connections Channels Exchanges Queues Admin							
Queues							
Virtual host: /							
Name	Type	Features	Messages read	Messages unack	Messages total	Incoming	State
news_articles	classic	D	94	0	94	0.00/s	running
news_errors	classic	D	6	0	6	0.00/s	running
news_urls	classic	D	13	0	13	0.00/s	running
Total queues: 3 Messages ready: 113 Messages total: 113							
RabbitMQ 3.13.0 Virtual host: / Node: rabbit@vps-news-parser							
Connected to http://localhost:15672 User: guest Uptime: 00:05:42							
2024-04-15 00:11:38 UTC							

02 · Catalog Parser — парсер каталогов товаров

Wildberries API · Ozon Playwright · Универсальный HTML по CSS-селекторам

Один CLI — три режима. Wildberries парсится через публичный API (search.wb.ru), Ozon — через Playwright + Chromium со скроллингом и кликом по пагинации, любой другой магазин — универсальным HTML-парсером по CSS-селекторам из YAML-конфига. Экспорт в CSV (UTF-8 BOM для Excel) и JSON.

- 10 полей на товар: id, name, brand, price, original_price, image, url, availability, rating, reviews
- Три типа пагинации: page_param, next_button, scroll_and_button (Ozon)
- HTTP-клиент с retry, ротацией UA, поддержкой HTTP_PROXY из .env (для residential proxy)
- Конфиги для WB и Ozon из коробки + generic_example.yaml как шаблон под новый магазин

Стек: Python 3.11+ · requests · BeautifulSoup4 · lxml · Playwright · PyYAML · pandas

03 · Price Monitor Bot — Telegram-бот мониторинга цен

[aiogram 3.x](#) · [FSM](#) · [APScheduler](#) · [aiosqlite](#)

Пользователь кидает ссылку на товар в бот — сохраняется в SQLite. Раз в 30 минут планировщик проверяет цену, сравнивает с предыдущей, пишет в `price_history` и, если цена изменилась, шлёт уведомление с дельтой в рублях и процентах.

- Команды `/start` `/add` `/list` `/remove` `/help`, FSM для добавления URL, inline-кнопки для удаления
- Поддерживаемые сайты: Wildberries (через `card.wb.ru` API), Ozon, Yandex.Market, DNS, М.Видео, Citilink
- Универсальный fallback: `itemprop=price`, `data-price`, `og:price:amount` — работает на любом `shop.ru`
- Две таблицы SQLite: `products` (UNIQUE `user_id+url`) и `price_history` (CASCADE DELETE)

Стек: Python 3.11+ · aiogram 3.4 · aiosqlite · APScheduler 3.10 · BeautifulSoup4 · SQLite

Все три проекта содержат: полный исходный код, README, requirements.txt, .env.example, .gitignore, техническое описание в PDF. Секреты не хардкодятся — только через переменные окружения.